

卒業論文 2018 年度 (平成 30 年)

低対話型 Honeypot のコマンド拡張による
収集ログの変化の計測

慶應義塾大学 総合政策学部
菅藤 佑太

低対話型 Honeypot のコマンド拡張による 収集ログの変化の計測

PC の普及や IoT デバイスのシステム高度化により、高度な処理系を組むことが可能になった。これによりデバイス上に Linux 系などの OS が搭載された機器が広く人々に使われるようになった。また、Linux 系 OS にリモートログインする手法として SSH がある。これを用いて不正に侵入する攻撃が行われている。侵入された際に侵入者がどのような挙動をしているのかを知る手段として、Honeypot がある。Honeypot は SSH で侵入しやすいような環境を作ることで、侵入者にログイン試行に成功したと検知させ、その際に実行したコマンドのログを収集するものである。また現在では Shell の挙動をエミュレートした Honeypot が広く使用されており、この Honeypot は実行できるコマンドが少ない実装になっている。そのため Honeypot への侵入者に侵入先が Honeypot であると検知されてしまう。そこで事前実験では Honeypot のコマンドを拡張し、拡張をしていない Honeypot とコマンドの拡張をした Honeypot で侵入ログを収集した。収集したログを確率的な算出方法を使用することで比較した結果、より多くの侵入者のコマンド実行ログのパターンを取得できることを示した。本研究ではコマンドを拡張した Honeypot の侵入ログがどれほど実際の OS に不正な SSH の侵入をされた際の侵入ログの近似を試みた。評価として、拡張をしていない Honeypot とコマンドの拡張をした Honeypot と、さらに実際の OS を使用した Honeypot で侵入ログを収集し、比較を行なった。この 3 つの侵入ログを自然言語処理の意味解析を用い、一セッションにおけるコマンドログの意味をベクトル空間上に表現することで、拡張した Honeypot で収集した侵入ログが、拡張をしていない Honeypot で収集した侵入ログよりも、一般的な UNIX ユーザーの実行するコマンドログから離れることが明らかとなった。

キーワード:

1. 自然言語処理, 2. 意味解析, 3. Honeypot, 4. SSH

慶應義塾大学 総合政策学部
菅藤 佑太

Measurement of changes in collection logs
by command extension of low interactive Honeypot

By the spread of PCs and the system advancement of the IoT device, I was able to make high processing system. The apparatus that the OS's such as the Linux system were equipped with on a device came to be in this way used for people widely. In addition, technique to perform a remote login for the Linux system OS includes SSH. An attack to invade using this illegally is carried out. A window includes Honeypot what kind of ways an intruder behaves when it was invaded. Honeypot lets an intruder detect it when I succeeded in a login trial by making the environment where it is easy to invade in SSH and collects the log of the command that I carried out on this occasion. In addition, Honeypot which emulated behavior of Shell is used widely now, and there are few commands that this Honeypot can carry out; is implemented. Therefore it is detected by an intruder to Honeypot when invasion is Honeypot. Therefore I expanded the command of Honeypot by the prior experiment and collected invasion log in Honeypot and Honeypot which I expanded of the command which were not expanded. As a result of having compared the log that I collected by using a probabilistic calculation method, I showed that I could acquire a pattern of the command practice log of more intruders. Invasion log of Honeypot which expanded the command tried an approximation of the invasion log when it was invaded of unjust SSH for the real OS in this study how long. I collected invasion log more in Honeypot using the real OS and compared it with Honeypot and expanded Honeypot of the command which were not expanded as an evaluation. I used semantic analysis of the natural language processing in the invasion log of these three, and it became clear to leave the command log that the UNIX user more general than the invasion log that I collected in Honeypot which the invasion log that I collected in Honeypot which I expanded by expressing a meaning of the command log in one session on a vector space did not expand carried out.

Keywords :

1. Natural Language Processing, 2. Semantic analysis, 3. Honeypot, 4. SSH

Keio University, Faculty of Policy Management Studies
Yuta Sugafuji

目次

第1章	序論	1
1.1	本研究の背景	1
1.1.1	通信機器の普及	1
1.1.2	honeypot	1
1.2	本研究の問題と仮説	1
1.3	提案手法の実装	2
1.4	予備実験	2
1.5	本研究の評価	2
1.5.1	予備実験	3
1.6	本論文の構成	3
第2章	本研究の要素技術	4
2.1	Honeypot	4
2.1.1	低対話型 Honeypot	4
2.1.2	高対話型 Honeypot	5
2.1.3	SSH の Honeypot の比較	5
2.2	Shell	6
2.2.1	Secure Shell	6
2.2.2	BusyBox	6
2.3	自然言語処理	6
2.3.1	混合隠れマルコフモデル	7
2.3.2	シソーラス解析	7
2.3.3	ベクトル空間解析	7
第3章	本研究における問題定義と仮説	17
3.1	本研究における問題定義	17
3.1.1	SSH Honeypot の現状の問題	17
3.1.2	本研究の問題	19
3.2	問題解決のための要点	19
3.3	仮説	19
3.3.1	コマンドの追加実装	19
3.3.2	既実装コマンドの修正	19

第 4 章	本研究の手法	20
4.1	問題解決の為のアプローチ	20
第 5 章	実装	21
5.1	実装環境	21
5.1.1	純正の Honeypot で未実装のコマンド種類	21
5.1.2	純正の Honeypot で未実装のコマンドの実装	22
第 6 章	評価と考察	27
6.1	予備実験	27
6.1.1	予備実験の手法	27
6.1.2	侵入ログの収集環境	27
6.1.3	実装	27
6.1.4	評価	28
6.1.5	結果	28
6.2	評価手法	29
6.2.1	コマンドログのスコアリング手法の実装の提案	30
6.2.2	機械学習を用いたコマンドログのスコアリング	31
6.3	考察	36
第 7 章	関連研究	37
7.1	関連研究	37
7.1.1	AccessTracer	37
7.1.2	自然言語処理における意味解析	37
第 8 章	結論	39
8.1	本研究のまとめ	39
8.2	本研究の課題と展望	39
8.2.1	文章ベクトルの評価指標	40
8.2.2	高対話型 Honeypot のログ収集の不足	40
8.2.3	ネットワークセグメントによるログ収集環境の違い	40
8.2.4	ディストリビューションごとの実装コマンド	40
8.2.5	様々な Honeypot のコマンドログの精度評価への応用	40
8.2.6	コマンド系ごとの評価への応用	40
付 録 A	付録	41
A.1	実装コマンド	41
A.1.1	純正の Honeypot で未実装のコマンド種類	41
A.1.2	純正の Honeypot で未実装のコマンドの実装	48
	謝辞	50

目 次

2.1	隠れマルコフモデル	7
2.2	入力ベクトルが出力ベクトルのどこに含まれているか	13
2.3	コンテキストサイズ C の Skip-gram Model のニューラルネットワーク	15
3.1	不正な SSH 侵入者の想定行動フロー	18
4.1	低対話型 Honeypot の拡張	20
6.1	純正の Cowrie と修正済の Cowrie のスコアリングによる比較	29
6.2	予備実験の評価の概念図	30
6.3	評価のフロー [1][2]	32
6.4	修正前と後の honeypot のコマンドログの文章ベクトルの可視化	34
6.5	修正前の honeypot と一般 UNIX ユーザーのコマンドログの文章ベクトル の可視化	35
6.6	修正後の honeypot と一般 UNIX ユーザーのコマンドログの文章ベクトル の可視化	35

表 目 次

2.1	種類ごとの Honeypot の比較	6
5.1	実装環境	21
6.1	予備実験の結果	28
6.2	修正前と後の honeypot のコマンドログの比較	33
6.3	修正前の honeypot と一般 UNIX ユーザーのコマンドログの比較	33
6.4	修正後の honeypot と一般 UNIX ユーザーのコマンドログの比較	33
7.1	word2vec による各々の honeypot のコマンドログの比較	38
A.1	実装コマンド一覧	41

第1章 序論

本章では本研究の背景，課題及び手法を提示し，本研究の概要を示す．

1.1 本研究の背景

1.1.1 通信機器の普及

PCの普及やIoTデバイスのシステム高度化により，高度な処理系を組むことが可能になった．これによりデバイス上にLinux系などのOSが搭載された機器が広く人々に使われるようになった．また，Linux系OSにリモートログインする手法としてSSHがある．これを用いて不正に侵入する攻撃が行われている．

1.1.2 honeypot

侵入された際に侵入者がどのような挙動をしているのかを知る手段として，Honeypotがある．これは実際のOSを用いたり，Shellの擬似的な挙動をアプリケーション上で実現し，敢えてSSHで侵入しやすいような環境を作ることで，侵入者にログイン試行に成功したと検知させ，その際に実行したコマンドのログを収集する．

1.2 本研究の問題と仮説

SSHのHoneypotは大きく二種類に分けることができ，一つは低対話型Honeypot，もう一つは高対話型Honeypotである．低対話型Honeypotは実際のShellの挙動をエミュレートしたアプリケーションである．

高対話型Honeypotは実際の機器を設置し，その中に侵入させログを収集する．その設置時には他のホストに攻撃できないようにネットワークの設定や，rootの権限が取られないようにuser権限の設定を適切に行う．高対話型Honeypotは低対話型Honeypotと比較すると，Honeypotへの侵入者が実行できるコマンドが多く，挙動も本物のOSと差異が極めて少なく，侵入先がHoneypotであると極めて検知しきれにくい．そのため，高精度な攻撃ログを取得することができる．しかし，Honeypotとして適切な設定を行なったOSが，設置後に発見された新たなOSの脆弱性を突かれることで，踏み台にされ他のホストに攻撃をしたりウイルスに犯されてしまうなどの危険を孕んでいる．そのため，設置コストが高く普及率も非常に低い．[3]

一方で低対話型 Honeypot はアプリケーションであるため、root 権限を取られるような危険が極めて少なく、アプリケーション内での脆弱性に限った問題しか存在しない。そのため設置コストが低く、比較的誰でも安全に設置できるため、普及率が高い。しかし、あくまでエミュレーションを行なったアプリケーションであるため、実際の Shell とは異なる挙動や、Honeypot に特有な挙動をすることがある。そのため、設置した Honeypot に侵入した悪意のあるユーザーに侵入先が Honeypot であると検知されてしまう可能性がある。本研究では低対話型 Honeypot に着目する。低対話型で実際の攻撃ログに近いログを収集するには、先述の Honeypot であることの検知を回避する必要がある。そこで本研究では、低対話型に実装されているコマンドの出力を、実際の Shell に近似することで検知を回避できるのではないかと考えた。

1.3 提案手法の実装

先述の Honeypot であることの検知を回避するために、本研究では低対話型 Honeypot を実際の Shell の挙動に近似するために、2つの実験を行なった。一つは実際の Shell に実装されているが低対話型 Honeypot に実装されていないコマンドの実装した。もう一つは低対話型 Honeypot に特有の異常な挙動を修正を行った。

1.4 予備実験

本研究の予備実験として、SSH の低対話型 Honeypot に実装されていないコマンドで、悪意のある侵入者が使うコマンドを実装することで拡張を行なった低対話型 Honeypot と、素の低対話型 Honeypot でそれぞれ収集したコマンドログの比較を行なった。追加実装を施した SSH の低対話型 Honeypot の方がコマンドパターンとして多く収集できることを示した。

1.5 本研究の評価

提案手法の実装で拡張した低対話型 Honeypot と、素の Honeypot と、高対話型 Honeypot を設置し、それぞれ侵入者が実行したコマンドのログを収集し、比較を行った。収集したコマンドのログはコマンド 1 つ 1 つごとに自然言語処理の手法を用いて意味解析をし、コマンドの意味をベクトル空間上に表現した。本研究では、高対話型のログに近似することで、高度なログが収集できていると考えた。そこで、素の Honeypot と拡張した低対話型 Honeypot と高対話型 Honeypot と比較して、どれほど一般的な UNIX ユーザーの実行するコマンドログから離れたのかを評価した。

1.5.1 予備実験

本研究の予備実験として、SSH の低対話型 Honeypot に実装されていないコマンドで、悪意のある侵入者が使うコマンドを実装することで拡張を行なった低対話型 Honeypot と、素の低対話型 Honeypot でそれぞれ収集したコマンドログの比較を行なった。追加実装を施した SSH の低対話型 Honeypot の方がコマンドパターンとして多く収集できることを示した。

1.6 本論文の構成

本論文における以降の構成は次の通りである。

2 章では、本研究の要素技術となる Shell と Honeypot と自然言語処理について整理する。3 章では、本研究における問題の定義と、解決するための要件、仮説について説明する。4 章では、本提案手法について解説する。5 章では、本研究の事前実験や Honeypot の拡張についての実装方法や実装例について述べる。6 章では、求められた課題に対しての評価を行い、考察する。7 章では、関連研究を紹介し、本研究との比較を行う。8 章では、本研究のまとめと今後の課題、展望についてまとめる。

第2章 本研究の要素技術

本章では，本研究の要素技術となる Shell と Honeypot と収集データの扱いについて各々整理する．

2.1 Honeypot

使われているデバイスへの不正な SSH によって侵入された際，実際に攻撃が行えない環境へとフォワードし，その中で攻撃を試行させ，侵入者のログを収集する手段として Honeypot がある．SSH の Honeypot[4] は低対話型 Honeypot と高対話型 Honeypot の大きく二種類に分けることができる．

2.1.1 低対話型 Honeypot

SSH の低対話型 Honeypot は実際の Shell の挙動をエミュレートしたアプリケーションである．実際の Shell の挙動をエミュレートしただけのアプリケーションなので，脆弱性がアプリケーション内に限られる．そのため，root 権限を侵入者に許してしまい，踏み台にされてしまうなどの危険が極めて少ない．しかし，エミュレーションには限界があるため，コマンドやその挙動について，実際の Shell とは異なる挙動をすることがある．そのため，侵入者に侵入先が Honeypot であると検知されてしまう．検知されることで，攻撃者は実際の攻撃を行わず，本来取れるはずの攻撃ログが収集できない可能性を含んでいる．そのため，収集ログの精度に問題がある．

2.1.1.1 Kippo

Kippo は，悪意のある SSH のログイン試行者や侵入者の挙動やログを記録するために使用される Python で実装された SSH の低対話型 Honeypot である [5]．Kippo は前身の Kojoney[?] に大きく影響を受けている．ネットワークは Twisted[?] というフレームワークで組まれている．Kippo のプロジェクトは低対話型 Honeypot として 2009 年に登場し，Raspberry Pi[?] などを筆頭としたシングルボードコンピュータ [6] の普及と相まって広く設置された．Kippo の機能の特徴としては収集したコマンドログを時系列データとして保存されており，”playlog”という Kippo 内にあるプログラムを実行することで，過去のコマンドログを実際にタイピングしてるかのように出力できる．また，侵入者によってダウン

ロードされたファイルも実行ができないように保存できる。Kippo は後述の Cowrie の後継実装である。[7] Kippo は IoT デバイスの高度化広く設置された SSH の低対話型 Honeypot のうちの一つであったが、実装されているコマンドも 77[8] と少なく、また Kippo 特有の異常な挙動が存在するなど多くの問題があった。

2.1.1.2 Cowrie

Cowrie は Python で実装された SSH の低対話型 Honeypot であり、実装は Kippo のコマンドの拡張や、攻撃者がリダイレクトでマルウェアを送り込む手法をとって送り込んだマルウェアを収集可能にしたりするなど、様々な機能を拡張したものである。Kippo 特有の異常な挙動を改善しており、実装コマンド数は 92[9] と Kippo より少し多くなっているものの [10]、Cowrie 特有の異常な挙動もまだまだ多い。

2.1.2 高対話型 Honeypot

高対話型 Honeypot は脆弱性を残した実際の OS を用いた Honeypot である。実際の OS をそのまますると、その OS から外部の他のホストへと攻撃することができてしまう。また、予期しない OS の脆弱性を突かれることで、OS 自体を完全に侵入者に制御されてしまう問題がある。そのため、Honeypot として適切な設定を行う必要がある。

2.1.2.1 Honeynet

2.1.2 で先述した通り、Honeypot で使用される OS から外部への通信で他のホストを攻撃したりするなどの攻撃を行ってしまう問題や、予期しない OS の脆弱性を突かれることで、OS 自体を完全に侵入者に制御されてしまう問題があるため、Honeypot として適切な設定を行う必要がある。そのため、Honeynet ではネットワーク全体を honeywall という独自のファイアウォールの機能を実行する。これは Honeypot のネットワークの設定を管理するだけではなく、ネットワーク介して送信されるすべてのデータの中央集権のポイントして機能する。これによってネットワークが危険にさらされた侵入者からの攻撃から保護することが可能である。[11]

2.1.3 SSH の Honeypot の比較

以上をまとめた SSH の低対話型 Honeypot と SSH の高対話型 Honeypot の比較を行った表を表 2.1 に示す。

表 2.1: 種類ごとの Honeypot の比較

Honeypot の種類	設置コスト (リスク)	Honeypot であることの検知されにくさ
低対話型 Honeypot	設置コストが低い	検知されやすい
高対話型 Honeypot	設置コストが高い	検知されにくい

2.2 Shell

Shell は OS のユーザーのためにインタフェースで、カーネルのサービスへのアクセスを提供するソフトウェアである。本研究での”Shell”はコマンドラインシェルのことを指す。

2.2.1 Secure Shell

Secure Shell (セキュアシェル、SSH) は、暗号や認証の技術を利用して、安全にリモートコンピュータと通信するためのプロトコルである。パスワードなどの認証部分を含むすべてのネットワーク上の通信が暗号化される。[12]SSH における問題としては、通信する上での認証方法には鍵認証を推奨されているが、デフォルトではパスワード認証になっている。パスワード認証のままだとパスワードの総当たり攻撃を受けたり、パスワードが標準のままの設定であることで不正なログイン試行によって侵入を許してしまう。

2.2.2 BusyBox

BusyBox は標準 UNIX コマンドで重要な多数のプログラムを単一のバイナリファイルに含むプログラムである。BusyBox に含まれる、多数の標準 UNIX コマンドで必要とするプログラムの実行ファイルは、Linux という OS を BusyBox だけでディストリビューションできるよう、”Linux 上で最小の実行ファイル”として設計されている。一般にインストールされる実行ファイルは一部だけを実装できるように選択することができる。一般的には BusyBox のコマンドは 200 以上も用意されている。[13]¹。BusyBox をインストールして実際に各コマンドを実行するためには、BusyBox 内にある各コマンドにアクセス可能なように path を通すだけで良い。

2.3 自然言語処理

人間が日常的に使っている自然言語をコンピュータに処理させる一連の技術である。本研究において、自然言語処理は意味解析のために使用した。意味解析には様々な手法があり、現在では大きくシソーラス解析とベクトル空間分析がある。

¹今回使用した BusyBox に含まれるコマンドの数は 219

2.3.1 混合隠れマルコフモデル

混合隠れマルコフモデルはいくつかの種類のある観測できない行動に対し、その行動に依存する何らかの観測を用いて隠れているデータのモデルを構築するモデルのことである。隠れ変数を Z_n とし、観測値を Y_n とすると、隠れマルコフモデルは以下の図 2.1 のように示すことができる。



図 2.1: 隠れマルコフモデル

2.3.2 シソーラス解析

シソーラスとは単語を意味レベルで分解し、抽象度の高いものから低いものへと遡っていくことができ、それを体系づけた類語辞書のことである。シソーラスには様々な言語において有名な辞書が存在する。有名なシソーラスとしては Princeton University の WordNet がある。[14]

2.3.2.1 Wordnet

WordNet は英単語が synset と呼ばれる同義語のグループに分類され、簡単な定義や、他の同義語のグループとの関係が記述されているデータベースである。WordNet のデータベースは約 11 万 5000 の synset に分類された約 15 万語を収録し、全体で 20 万 3000 の単語と意味の組み合わせがある。[15]

2.3.3 ベクトル空間解析

単語の意味を表現するため、単語の文章での出現回数や、その単語の周辺の単語をマトリクス上に表現することで、その単語を数学的に解釈できるようにしている。

2.3.3.1 ベクトル空間モデル

ベクトル空間モデルとは文章を多次元空間上にベクトルとして表現し、それぞれのベクトルの比較を行うことで類似度を算出するためのモデルである。文章の類似度が高いほどベクトルの方向が近いということなので、比較した文章のベクトルのなす角が小さければ文章の類似度が高いということになる。

m 個の単語が使用されている文章 d における各単語の重要度を $w_{d1}, w_{d2}, w_{d3}, \dots, w_{dm}$ とすると、文章 d のベクトルは以下のように表される。

$$\vec{d} = (w_{d1}, w_{d2}, w_{d3}, \dots, w_{dm})$$

また、同様にして n 個の単語が使用されている文章 e をベクトル表現すると、

$$\vec{e} = (w_{e1}, w_{e2}, w_{e3}, \dots, w_{en})$$

と表すことができる。したがって、 \vec{d} と \vec{e} のなす角 θ における $\cos \theta$ は以下のように表される。

$$\cos \theta = \frac{\vec{d} \cdot \vec{e}}{|\vec{d}| |\vec{e}|}$$

ベクトル化した時の単語の重要度は TF-IDF のアルゴリズム (※ 2.3.3.1.1) を用いて算出した重みを用いることで、これを表すことができる。[16] 上記の例であれば、文章 d における単語の重要度が $tf(t_1, d) \cdot idf(t_1), tf(t_2, d) \cdot idf(t_2), tf(t_3, d) \cdot idf(t_3), \dots, tf(t_m, d) \cdot idf(t_m)$ であるので、文章 d のベクトルは以下のように表される。

$$\vec{d} = (tf(t_1, d) \cdot idf(t_1), tf(t_2, d) \cdot idf(t_2), tf(t_3, d) \cdot idf(t_3), \dots, tf(t_m, d) \cdot idf(t_m))$$

また、同様にして文章 e もベクトル表現すると、

$$\vec{e} = (tf(t_1, e) \cdot idf(t_1), tf(t_2, e) \cdot idf(t_2), tf(t_3, e) \cdot idf(t_3), \dots, tf(t_n, e) \cdot idf(t_n))$$

と表すことができ、これを $\cos \theta = \frac{\vec{d} \cdot \vec{e}}{|\vec{d}| |\vec{e}|}$ に代入すると ($\ast m \leq n$),

$$\begin{aligned}
 \cos \theta &= \frac{\vec{d} \cdot \vec{e}}{|\vec{d}| |\vec{e}|} \\
 &= \frac{((tf(t_1, d) \cdot idf(t_1))(tf(t_1, e) \cdot idf(t_1)) + (tf(t_1, d) \cdot idf(t_2))(tf(t_2, e) \cdot idf(t_2)) + \dots \\
 &\quad + (tf(t_m, d) \cdot idf(t_m))(tf(t_m, e) \cdot idf(t_m)))}{\sqrt{(tf(t_1, d) \cdot idf(t_1))^2 + (tf(t_2, d) \cdot idf(t_2))^2 + \dots + (tf(t_m, d) \cdot idf(t_m))^2} \cdot \sqrt{(tf(t_1, e) \cdot idf(t_1))^2 + (tf(t_2, e) \cdot idf(t_2))^2 + \dots + (tf(t_n, e) \cdot idf(t_n))^2}} \\
 &= \frac{\sum_{i=1}^m ((tf(t_i, d) \cdot idf(t_i))(tf(t_i, e) \cdot idf(t_i)))}{\sum_{i=1}^m \sqrt{(tf(t_i, d) \cdot idf(t_i))^2} \sum_{i=1}^n \sqrt{(tf(t_i, e) \cdot idf(t_i))^2}} \quad (2.1)
 \end{aligned}$$

と表すことができる。これがベクトル空間で TF-IDF で抽出した単語の重み付けを行い、二つの文章の類似度を算出するモデルである。

2.3.3.1.1 TF-IDF

TF とは Term Frequency のことで、文章内での単語の出現頻度を表す。数式では以下のように表される。

$$tf(t, d) = \frac{n_{t, d}}{\sum_{s \ni d} n_{s, d}}$$

$tf(t, d)$ は TF の値で、文章 d 内に含まれる単語 t の出現頻度を表す。
 $n_{t, d}$ は文章 d における単語 t の出現回数を表す。
 $\sum_{s \ni d} n_{s, d}$ は文章 d における全ての単語の出現回数を表す。
 以上を踏まえ TF の値とは、

$$\text{文章 } d \text{ 内に含まれる単語 } t \text{ の出現頻度} = \frac{\text{文章 } d \text{ における単語 } t \text{ の出現回数}}{\text{文章 } d \text{ における全ての単語の出現回数}}$$

を数式で表したものである。

IDF とは Inverse Document Frequency のことで、ある単語が様々な文章においてどれほど使われているのかを表す。数式では以下のように表される。

$$idf(t) = \log \frac{N}{df(t)} + 1$$

$idf(t)$ は IDF の値で、単語 t が全文章数 N でどれほど使われているのかを表す。
 N は全文章数を表す。

$df(t)$ は単語 t が出現する文章の数を表す。
 以上を踏まえ IDF の値とは,

$$\text{単語 } t \text{ が全文章数 } N \text{ でどれほど使われているのか} = \frac{\text{全文章数}}{\text{単語 } t \text{ が出現する文章の数} + 1}$$

を数式で表したものである。
 このような TF の値と IDF の値を重みとすることで、文章を特徴付ける単語の抽出をするものが TF-IDF である。上記の TF と IDF の値より、if-idf の値は

$$ifidf(t, d) = tf(t, d) \cdot idf(t)$$

から算出することができる。

2.3.3.2 word2vec

word2vec は 2 層からなるニューラルネットワークである。word2vec には 2 つのアーキテクチャがあり、一つは *ContinuousSkip-gramModel*、もう一つは *ContinuousBag-of-WordsModel* である。*ContinuousSkip-gramModel* は入力に文章中の任意の単語を用意し、出力に文章においてその任意の単語の前後の周辺語を用意し、ニューラルネットワークに読み込ませることで第一層から第二層への重みを獲得することが目的である。*ContinuousBag-of-WordsModel* では逆に出力に文章中の任意の単語を用意し、入力に文章においてその任意の単語の前後の周辺語を用意し、同様にしてニューラルネットワークに読み込ませることで第一層から第二層への重みを獲得することが目的である。本研究ではより精度の高い *ContinuousSkip-gramModel* (以降、*Skip-gramModel* と呼ぶ。) を使用した。[1]

2.3.3.3 Continuous Skip-gram Model

Skip-gramModel は先述の通り、与えられた単語に対してその周辺語を予測するためのモデルのことである。このモデルは 2 層からなるニューラルネットで、入力には One-hot ベクトルを用いる。One-hot ベクトルとは $(0, 0, 0, \dots, 1, \dots, 0)$ のように、単語のインデックスから抽出する単語だけを 1 と表記することで表現するベクトルのことである。

入力層から隠れ層への重みは $V \times N$ のマトリクス W で表され、 W の各列は単語ベクトルとなっている。隠れ層から出力層への重みはマトリクス W を転置した $N \times V$ のマトリクス W' となっている。

これをモデル化したものの出力の条件付き確率を考える。

$$p(w_O|w_I) = \frac{\exp(v_{W_V}^T \cdot v_{w_I})}{\sum_{w_v \in V} \exp(v_{W_V}^T \cdot v_{w_I})} \quad (2.2)$$

この w_I は入力する単語, w_O は w_I の周辺語を表す. v_{w_I} や v'_{W_V} は単語を表すベクトルであり, v は入力ベクトルで v' は出力ベクトルである. コンテキストサイズとは先述したように, 入力単語の周辺語をどこまでとするかのサイズのことである. $p(w_O|w_I)$ はコンテキストサイズを考慮していない確率であるが, このコンテキストサイズを考慮して先述したモデルの同時確率 $p(w_{O,1}, w_{O,2}, w_{O,3}, \dots, w_{O,C}|w_I)$ を考える.

$$p(w_{O,1}, w_{O,2}, w_{O,3}, \dots, w_{O,C}|w_I) = \prod_{c=1}^C \frac{\exp(v'_{W_c} \cdot v_{w_I})}{\sum_{w_v \in V} \exp(v'_{W_V} \cdot v_{w_I})} \quad (2.3)$$

この $p(w_{O,1}, w_{O,2}, w_{O,3}, \dots, w_{O,C}|w_I)$ という確率を表す関数 $\prod_{c=1}^C \frac{\exp(v'_{W_c} \cdot v_{w_I})}{\sum_{w_v \in V} \exp(v'_{W_V} \cdot v_{w_I})}$ が最大となるような単語ベクトル v を求めることが, このモデルの目的である.

このモデルを用いてニューラルネットを構築する. 先述の通り, 入力層 x は One-hot ベクトルを用いる. One-hot ベクトルとは $(0, 0, 0, \dots, 1, \dots, 0)$ のように, 単語のインデックスから抽出する単語だけを 1 と表記することで表現するベクトルのことである.

隠れ層 h は, 入力層から隠れ層への重み W を入力データ x にかけてのものである. したがって隠れ層 h は

$$h = Wx$$

と表すことができる. また, 任意の入力 $w_I (= x_i)$ は重み W が掛けられるが, 入力 x が One-hot ベクトルなので, w_I に対応する単語ベクトルがそのまま出力されることになる. したがって, 隠れ層は

$$h = Wx_{w_I} = v_{w_I}$$

と表すことができる.

出力層 u_c は, 隠れ層 h に隠れ層から出力層への重み W' が掛けられたものであるので,

$$u_c = W'h = W'v_{w_I}$$

と表すことができる. また, 出力層はコンテキストサイズに応じて出力のユニット数 c が変動する. したがって, 任意のユニット C における最終的な出力 $y_{c,i}$ に softmax 関数を掛けて,

$$\begin{aligned} y_{c,i} &= \frac{\exp(u_{c,i})}{\sum_{v=1}^V \exp(u_{c,v})} \\ &= \frac{\exp(v'_i \cdot v_{w_I})}{\sum_{v=1}^V \exp(v'_v \cdot v_{w_I})} \\ &= p(w_i|w_I) \end{aligned}$$

と表され, 式 (2.2) で表した確率と同じになることが確認できる.

したがって式 (2.3) で表された同時確率 $p(w_1, w_2, w_3, \dots, w_C|w_I)$ の最大化をするために,

単語ベクトル v と単語ベクトル v' を最適化する．すなわち重み W と重み W' を最適化することを考える．word2vec では最適化のために確率的勾配降下法を用いており，目的関数として以下の式 (2.4) を定める．

$$E = -\log p(w_1, w_2, w_3, \dots, w_C | w_I) \quad (2.4)$$

後述の損失関数の導出を円滑にするため，最大化問題から最小化問題へするために負の符号を付し，また同時確率であることから確率の値が極端に小さくなる可能性を考慮し，対数を取ることで乗法から和法へと変換することでアンダーフローを防いだ．

式 (2.4) に式 (2.3) を代入すると，

$$\begin{aligned} E &= -\log p(w_1, w_2, w_3, \dots, w_C | w_I) \\ &= -\log \prod_{c=1}^C \frac{\exp(u_{C,w_C})}{\exp(\sum_{v=1}^V \exp(u_{C,v}))} \\ &= -\sum_{C=1}^C \log \frac{\exp(u_{C,w_C})}{\exp(\sum_{v=1}^V \exp(u_{C,v}))} \quad (\because \log_a MN = \log_a M + \log_a N) \\ &= -\sum_{C=1}^C (\log \exp(u_{C,w_C}) - \log \sum_{v=1}^V \exp(u_{C,v})) \quad (\because \log_a \frac{M}{N} = \log_a M - \log_a N) \\ &= -\sum_{C=1}^C (u_{C,w_C} - \log \sum_{v=1}^V \exp(u_{C,v})) \quad (\because \log_e \exp(x) = x) \end{aligned} \quad (2.5)$$

となる．この式 (2.5) を重み W と重み W' で偏微分し，誤差を求めることを考える．まずは重み W' で E を偏微分し， W' の更新式を得る．また，以下の図 2.2 は，入力ベクトルが出力ベクトルのどこに含まれているのかを表したものである．



図 2.2: 入力ベクトルが出力ベクトルのどこに含まれているか

つまり, v'_{ij} は u_C の内, i 番目の要素 $u_{c,i}$ に含まれていると言える. コンテキストサイズは C なので, C 個の多変数関数であり, 連鎖律を用いると,

$$\frac{\partial E}{\partial v'_{ij}} = \sum_{C=1}^C \frac{\partial E}{\partial u_{c,i}} \frac{\partial u_{c,i}}{\partial v'_{ij}} \quad (2.6)$$

とすることができる. 式 (2.6) の右辺より, E を $u_{c,i}$ でまずは微分することを考える. 式 (2.5) を変形して,

$$\begin{aligned} E &= - \sum_{C=1}^C (u_{C,w_C} - \log \sum_{V=1}^V \exp(u_{C,V})) \\ &= - \sum_{C=1}^C u_{C,w_C} + \sum_{C=1}^C \log \sum_{V=1}^V \exp(u_{C,V}) \end{aligned} \quad (2.7)$$

式 (2.7) の内, $\sum_{C=1}^C u_{C,w_C}$ を $u_{c,i}$ で微分することを考える.

$$\sum_{C=1}^C u_{C,w_C} = u_{1,w_1} + u_{2,w_2} + \dots + u_{C,w_C} \quad (2.8)$$

と変換することで,

$$\frac{\partial \sum_{C=1}^C u_{C,w_C}}{\partial u_{c,i}} := t_{c,i} \left\{ \begin{array}{ccc} 1 & & \\ (i = w_c) & 0 & otherwise. \end{array} \right\} \quad (2.9)$$

とすることができる．次に $\sum_{C=1}^C \log \sum_{V=1}^V \exp(u_{C,V})$ の部分について,

$$\begin{aligned} g &= \sum_{V=1}^V \exp(u_{C,V}) f = \log g \frac{df}{dg} \frac{dg}{du_{c,i}} = \frac{1}{g} \exp(u_{c,i}) \\ &= \frac{\exp(u_{c,i})}{\exp(\sum_{v=1}^V \exp(u_{c,v}))} \\ &= y_{c,i} \end{aligned} \quad (2.10)$$

式 (2.9) と式 (2.10) より,

$$\frac{\partial E}{\partial u_{c,i}} = -t_{c,i} + y_{c,i} \quad (2.11)$$

さらに, 式 (2.6) の $\frac{\partial u_{c,i}}{\partial v'_{ij}}$ の部分は,

$$\frac{\partial u_{c,i}}{\partial v'_{ij}} = v_{w_{Ij}} \quad (2.12)$$

$$(\because u_{c,i} = v'_{i1} v_{w_I 1} + v'_{i1} v_{w_I 1} + \dots + v'_{ij} v_{w_I j} + \dots + v'_{iN} v_{w_I N}) \quad (2.13)$$

したがって, 式 (2.6) と式 (2.11) と式 (2.12) より,

$$\frac{\partial E}{\partial v'_{ij}} = \sum_{C=1}^C (y_{c,i} - t_{c,i}) v_{w_{Ij}} \quad (2.14)$$

が得られる．

以上をまとめると, Skip-gram Model のニューラルネットワークは以下の図 2.3 のようになる．

図 2.3: コンテキストサイズ C の Skip-gram Model のニューラルネットワーク

2.3.3.4 SCDV

SCDV とは word2vec で算出したベクトル空間をクラスタリングして、クラスタリング結果も考慮に入れてベクトル空間上に再表現する手法のことである。以下は公式ドキュメントである。まず、ある単語 w_i のベクトル w_i を取得 (word2vec)。ある単語 w_i の IDF 値 $\text{idf}(w_i)$ を計算する。GMM で全単語ベクトルについてクラスタリングを行い、ある単語が各クラス c_k に属する確率 $P(c_k | w_i)$ を取得する。語彙空間における各単語 w_i について 5 を繰り返す。各クラス c_k についてクラスの数だけ (*) を繰り返す。クラスの数だけ計算したら、(**) を実行する。(*) クラスを考

慮した新たな単語ベクトル $w_{cvi}k_{cvi}$ を $w_{vi} \times P(c_k - w_i)w_{vi} \times P(c_k - w_i)$ として算出.
 (**) IDF を考慮した新たな単語ベクトル $w_{tvi}w_{tvi}$ を $idf(w_i) \times Kk \quad w_{cvi}idf(w_i) \times kK$
 $w_{cvi}k$ で算出 (は concatenation). 各ドキュメント (n から Nn から N) について 9 の操
 作を繰り返す. ドキュメント $DnDn$ についてベクトルを初期化し, $DnDn$ に含まれる単語
 $wiinDnwiinDn$ についてベクトルを足し合わせていき平均する. 最後に得られた文書ベク
 トル $DnDn$ をスパースにして $SCDVDnSCDVDn$ を得る. [17]

第3章 本研究における問題定義と仮説

本章では、1章で述べた背景より、本章では、現状の Honeypot の問題点を整理し、この問題をどのように解決すれば良いのかを定義する。

3.1 本研究における問題定義

現状の Honeypot の問題点を列挙し、整理する。

3.1.1 SSH Honeypot の現状の問題

Honeypot には運用する上で大きな問題が2つある。一つは設置した Honeypot に侵入した悪意のある侵入者が侵入先を Honeypot であると検知してしまう問題である。もう一つは Honeypot に侵入を許した侵入者に Honeypot を設置した機器から他のホストに攻撃を仕掛けられてしまう、所謂踏み台攻撃の踏み台にされる問題である。

以下の図 3.1 は、悪意のある侵入者が不正に機器に侵入してから踏み台にして他の機器に攻撃を仕掛けるまでの一般的なフローである。問題として、2番目のフローの悪意のある侵入者が侵入した先が Honeypot であると検知してしまうことが考えられる。高対話型 Honeypot で使用した OS 自体の新たな脆弱性を突かれることに限った状況で、3番目のフローの Honeypot への侵入者に Honeypot を設置した機器から攻撃が仕掛けられてしまう危険があることが問題として挙げられる。

本研究ではこの中でも、2番目のフローの SSH の低対話型 Honeypot が設置した Honeypot に悪意のある侵入者が侵入先を Honeypot であると検知してしまう問題に着目した。

3.1.1.1 SSH の低対話型 Honeypot における問題

SSH の低対話型 Honeypot は実際の Shell の挙動をエミュレートしたものであるのでコマンドやその挙動についての機能が限定されており、実際の Shell の機能として不足がある。また SSH の低対話型 Honeypot 特有の以上な挙動も存在する。さらに、Honeypot の username のデフォルトが決まっているため、username から Honeypot であることを検知されてしまう問題もある。これらの検知手法を用いて、侵入者に侵入先が Honeypot であると検知され、本来取れるはずの攻撃ログが収集できない問題がある。



図 3.1: 不正な SSH 侵入者の想定行動フロー

3.1.1.1.1 Honeypot の Username の問題

SSH の低対話型 Honeypot の内、特に Cowrie は kippo を改良したものであるため、kippo のデフォルトの username である”Richard”が cowrie の username となっている。このため、username が”Richard”で、honeypot 特有の挙動をした場合に、侵入者に Honeypot であると検知されてしまう。

3.1.1.1.2 Honeypot のコマンドの実装の問題

SSH の低対話型 Honeypot は実際の Shell の挙動をエミュレートしたものであるのでコマンドやその挙動についての機能が限定されており、実際の Shell の機能として不足がある。2.2.2 で述べたように、”Linux 上で最小の実行ファイル”となるよう設計されている BusyBox に含まれるコマンドの数が 200 以上あるのに対し、現状で広く使われている SSH の低対話型 Honeypot である Cowrie に実装されているコマンドは 2.1.1.2 でも述べた通り、92 しか存在しない。また、SSH の低対話型 Honeypot 特有の挙動が存在し、以下にその 1 例であるプログラム 3.1 とプログラム 3.2 を示す。

プログラム 3.1: 正しい Shell の挙動

```

1 nadechin@cpu:~$ echo -n test
2 testnadechin@cpu:~$

```

プログラム 3.2: Kippo 特有の異常な挙動の例

```

1 root@localhost-neco:~$ echo -n hello
2 -n hello
3 root@localhost-neco:~$

```

プログラム 3.1 が通常の挙動でプログラム 3.2 が SSH の低対話型 Honeypot の挙動である。echo コマンドの -n オプションは改行出力末尾にしないようにするものである。しかし、実際の Shell の出力は改行がされない一方、Honeypot の挙動ではオプション部分

も出力されてしまい、末尾も改行されてしまう。これは SSH の低対話型 Honeypot 特有の挙動であるため、この挙動を観測することによって侵入者に侵入先が Honeypot であると検知されてしまう可能性がある。

3.1.2 本研究の問題

3.1.1.1 で列挙した SSH の低対話型 Honeypot の問題の中で、実際の Shell に実装されているコマンドの不足がある。また SSH の低対話型 Honeypot に特有の異常な挙動も存在するため、設置した Honeypot が悪意のある侵入者に侵入先を Honeypot であると検知されてしまい、実際の OS に悪意のある侵入者が侵入した時の侵入ログとの違いが大きく出てしまう問題に着目した。

3.2 問題解決のための要点

3.1.2 で着目した問題を解決するためには、以下 2 つの手法を取る必要がある。

コマンドの追加実装: 実際の Shell に実装されているコマンドで、SSH の低対話型 Honeypot に実装されていないコマンドを実装する

既実装コマンドの修正: SSH の低対話型 Honeypot に特有の異常な挙動をする既実装コマンドを修正する

3.3 仮説

3.3.1 と 3.3.2 で示す問題解決のための要点を踏まえると、SSH の低対話型 Honeypot に侵入した悪意のある侵入者に侵入先を Honeypot であると検知させず、SSH の低対話型 Honeypot に悪意のある侵入者が侵入した時の侵入ログを、実際の OS に悪意のある侵入者が侵入した時の侵入ログに近似できるのでないかと考えた。

3.3.1 コマンドの追加実装

実際の Shell に実装されているコマンドで、SSH の低対話型 Honeypot に実装されていないコマンドを実装することで、Honeypot への侵入者が実行できるコマンドの少なさによる、Honeypot であることの検知を回避することができる。

3.3.2 既実装コマンドの修正

SSH の低対話型 Honeypot に特有の異常な挙動をする既実装コマンドを修正することで、Honeypot について認知している侵入者が、侵入先を Honeypot であると検知することを回避することができる。

第4章 本研究の手法

本章では，3.3 節で述べた仮説を検証するために，本研究の手法について概説する．

4.1 問題解決の為のアプローチ

3.2 で述べた問題解決のための2つの要件を満たすために，本研究では低対話型 Honeypot に実装されていないコマンドを実装し，さらに低対話型 Honeypot の既実装コマンドで，低対話型 Honeypot に特有の異常な挙動をするコマンドの修正を行う．略図を図 4.1 に示す．




図 4.1: 低対話型 Honeypot の拡張

第5章 実装

本章では，低対話型 Honeypot と高対話型 Honeypot の設置環境についても示し，4.1 節で述べた手法を用いて純正の Honeypot にどのようなコマンドを実装し，Honeypot 特有の異常な挙動を修正したのかを説明する．

5.1 実装環境

本研究で実装するシステムを構成するためのハードウェアおよびソフトウェアについて説明する．表 5.1 に詳細なバージョンを示す．

表 5.1: 実装環境

ハードウェア/ソフトウェア	実装環境	Version(date)
純正の Cowrie	CentOS5	1. 4. 0
修正済みの Cowrie	CentOS5	1. 4. 0 (self made)
Honeywall	CentOS5	1. 4

5.1.1 純正の Honeypot で未実装のコマンド種類

本研究において純正の Honeypot は Cowrie[18] を使用し，実際の Shell には実装されているが，純正の Honeypot で未実装のコマンドについては BusyBox[13] に含まれるコマンドの実装を行なった．2.2.2 や ??で紹介した通り，BusyBox に含まれるコマンドの種類が 219 ある中で，Cowrie の実装コマンド数は 92 しか存在しない．この差分を Python で実装する．

また BusyBox に含まれるコマンドと Cowrie の実装コマンド，Cowrie に未実装のコマンドの一覧は付録 A の表 A.1 に示しておく．

5.1.2 純正の Honeypot で未実装のコマンドの実装

5.1.1 で示した Cowrie に未実装のコマンドについての一部の実装を示す。他の実装は A.1.2 の表に示す。Cowrie に実装されているコマンドは `cowrie/src/cowrie/commands/` に格納されており、ここに追加コマンドを実装する。

以下の 5.1 に `cowrie/src/cowrie/commands/base.py` に `dmidecode` コマンドを追加実装したものを示す。[19]

プログラム 5.1: `dmidecode`

```

1 class command_dmidecode(HoneyPotCommand):
2     """
3     """
4     def call(self):
5         """
6         """
7         self.write(b"###dmidecode 3.1
8 Getting SMBIOS data from sysfs.
9 SMBIOS 3.0.0 present.
10 Table at 0xDDBA4000.
11
12 (snip)
13
14 Handle 0x0055, DMI type 13, 22 bytes
15 BIOS Language Information
16 Language Description Format: Long
17 Installable Languages: 1
18 en|US|iso8859-1
19 Currently Installed Language: en|US|iso8859-1
20
21 Handle 0x0056, DMI type 127, 4 bytes
22 End Of Table\n""")
23 commands['dmidecode'] = command_dmidecode

```

追加実装以外ではファイルを追加することで、コマンドを追加したものを以下の 5.2 に示す。[?]

プログラム 5.2: `diff` コマンド

```

1 # coding: utf-8
2 import sys
3
4 class Diff:
5     def __init__(self, a, b):
6         self.a = a
7         self.b = b

```

```
8
9     def solve(self):
10         self.result = None
11         self.createTable()
12         self.selectMatches()
13         self.connectPath()
14         self.genResult()
15         return self.result
16
17     def createTable(self):
18         self.table = [[x == y for y in self.b] for x in self.a]
19
20     def selectMatches(self):
21         self.matches = [ (i, j)
22             for i in range(len(self.table))
23             for j in range(len(self.table[i]))
24             if self.table[i][j]]
25
26         self.max_path = []
27         self.path = []
28
29         self.search((-1, -1)) # 左上から探索
30         # print self.max_path
31
32     def search(self, pos):
33         def isReachable(pos, match):
34             return match[0] > pos[0] and match[1] > pos[1]
35
36         if pos != (-1, -1): self.path.append(pos)
37         is_term = True
38         for match in self.matches:
39             if isReachable(pos, match):
40                 is_term = False
41                 next_pos = match
42                 self.search(next_pos)
43
44         if is_term: # 終端の場合
45             if len(self.path) > len(self.max_path):
46                 self.max_path = list(self.path) # 最良経路の更新
47             if pos != (-1, -1): self.path.pop()
48
49     def connectPath(self):
50         # self.path = [(0, 0)]
51         self.path = []
52         prev = (0, 0)
53         for pos in self.max_path:
54             p = prev
```

```

55     while p[0] < pos[0]:
56         p = (p[0] + 1, p[1])
57         self.path.append(p)
58     while p[1] < pos[1]:
59         p = (p[0], p[1] + 1)
60         self.path.append(p)
61     p = (p[0] + 1, p[1] + 1)
62     self.path.append(p)
63     prev = p
64     p = prev
65     while p[0] < len(self.table):
66         p = (p[0] + 1, p[1])
67         self.path.append(p)
68     while p[1] < len(self.table[0]):
69         p = (p[0], p[1] + 1)
70         self.path.append(p)
71     # print self.path
72
73     def genResult(self):
74         prev = (0, 0)
75         i_a = 0
76         i_b = 0
77         self.result = []
78         for pos in self.path:
79             if pos == (0, 0): continue
80             if pos[1] == prev[1]: # 縦への移動 : a の -
81                 self.result.append((self.a[i_a], '-'))
82                 i_a += 1
83             elif pos[0] == prev[0]: # 横への移動 : b の +
84                 self.result.append((self.b[i_b], '+'))
85                 i_b += 1
86             else: # 斜めへの移動
87                 self.result.append((self.a[i_a], ' '))
88                 i_a += 1
89                 i_b += 1
90             prev = pos
91             # print self.result
92
93     def printResult(self):
94         for line, sign in self.result:
95             print sign, line,
96
97     def diff(filename_a, filename_b):
98         a = []
99         with open(filename_a) as f:
100             for line in f:
101                 a.append(line)

```

```

102
103     b = []
104     with open(filename_b) as f:
105         for line in f:
106             b.append(line)
107
108     # a = ['a', 'b', 'c', 'd', 'e', 'f', 'g']
109     # b = ['a', 'b', 'x', 'c', 'y', 'e', 'g']
110     solver = Diff(a, b)
111     result = solver.solve()
112     solver.printResult()
113
114 if __name__ == "__main__":
115     if len(sys.argv) != 3:
116         print "Usage: python %s fileA fileB" % sys.argv[0]
117         quit()
118     diff(sys.argv[1], sys.argv[2])

```

さらに、コマンド実行時に出力結果を print 関数で出力するのみのコマンド追加したものの例を以下の 5.3 示す。本例では mount コマンドを以下のように実装した。

プログラム 5.3: mount コマンド

```

1  # coding: utf-8
2
3  string = '''sysfs on /sys type sysfs (rw,nosuid,nodev,
         noexec,relatime)
4  proc on /proc type proc (rw,nosuid,nodev,noexec,relatime)
5  udev on /dev type devtmpfs (rw,nosuid,relatime,size
         =16459820k,nr_inodes=4114955,mode=755)
6  devpts on /dev/pts type devpts (rw,nosuid,noexec,relatime,
         gid=5,mode=620,ptmxmode=000)
7  tmpfs on /run type tmpfs (rw,nosuid,noexec,relatime,size
         =3294084k,mode=755)
8  /dev/sda1 on / type ext4 (rw,relatime,discard,data=ordered)
9  securityfs on /sys/kernel/security type securityfs (rw,
         nosuid,nodev,noexec,relatime)
10 tmpfs on /dev/shm type tmpfs (rw,nosuid,nodev)
11 tmpfs on /run/lock type tmpfs (rw,nosuid,nodev,noexec,
         relatime,size=5120k)
12 tmpfs on /sys/fs/cgroup type tmpfs (ro,nosuid,nodev,noexec,
         mode=755)
13 cgroup on /sys/fs/cgroup/systemd type cgroup (rw,nosuid,
         nodev,noexec,relatime,xattr,release_agent=/lib/systemd/
         systemd-cgroups-agent,name=systemd)
14 pstore on /sys/fs/pstore type pstore (rw,nosuid,nodev,
         noexec,relatime)

```



```

15 cgroup on /sys/fs/cgroup/net_cls,net_prio type cgroup (rw,
    nosuid,nodev,noexec,relatime,net_cls,net_prio)
16 cgroup on /sys/fs/cgroup/freezer type cgroup (rw,nosuid,
    nodev,noexec,relatime,freezer)
17 cgroup on /sys/fs/cgroup/pids type cgroup (rw,nosuid,nodev,
    noexec,relatime,pids)
18 cgroup on /sys/fs/cgroup/cpuset type cgroup (rw,nosuid,
    nodev,noexec,relatime,cpuset)
19 cgroup on /sys/fs/cgroup/cpu,cpuacct type cgroup (rw,nosuid
    ,nodev,noexec,relatime,cpu,cpuacct)
20 cgroup on /sys/fs/cgroup/memory type cgroup (rw,nosuid,
    nodev,noexec,relatime,memory)
21 cgroup on /sys/fs/cgroup/devices type cgroup (rw,nosuid,
    nodev,noexec,relatime,devices)
22 cgroup on /sys/fs/cgroup/hugetlb type cgroup (rw,nosuid,
    nodev,noexec,relatime,hugetlb)
23 cgroup on /sys/fs/cgroup/rdma type cgroup (rw,nosuid,nodev,
    noexec,relatime,rdma)
24 cgroup on /sys/fs/cgroup/blkio type cgroup (rw,nosuid,nodev
    ,noexec,relatime,blkio)
25 cgroup on /sys/fs/cgroup/perf_event type cgroup (rw,nosuid,
    nodev,noexec,relatime,perf_event)
26 systemd-1 on /proc/sys/fs/binfmt_misc type autofs (rw,
    relatime,fd=26,pgrp=1,timeout=0,minproto=5,maxproto=5,
    direct,pipe_ino=11662)
27 debugfs on /sys/kernel/debug type debugfs (rw,relatime)
28 mqueue on /dev/mqueue type mqueue (rw,relatime)
29 hugetlbfs on /dev/hugepages type hugetlbfs (rw,relatime,
    pagesize=2M)
30 configfs on /sys/kernel/config type configfs (rw,relatime)
31 fusectl on /sys/fs/fuse/connections type fusectl (rw,
    relatime)
32 /dev/sdb1 on /mnt type ext4 (rw,relatime,data=ordered)
33 lxcfs on /var/lib/lxcfs type fuse.lxcfs (rw,nosuid,nodev,
    relatime,user_id=0,group_id=0,allow_other)
34 tmpfs on /run/user/1000 type tmpfs (rw,nosuid,nodev,
    relatime,size=3294084k,mode=700,uid=1000,gid=1000)'''
35
36 print(string)

```

残りのコマンドについては A.1.2 に記す。

第6章 評価と考察

本章では、予備実験と5章で実装した本研究での提案手法の評価とその考察を述べる。

6.1 予備実験

SSHの低対話型HoneypotであるCowrieはコマンドの実装数が少なく、Cowrie特有の異常な挙動が多い。そのため、侵入者にHoneypotであると検知されることで、本来実際のOSへの攻撃であれば取れるはずであった侵入ログが取れない問題がある。また、収集ログを分析する際に、これまで用いられてきた”危険なコマンド”としてインデックスを作り、それらを危険なコマンドとしてパターンマッチングする手法では、今後出現してくる様々なコマンドパターンなどに対応できない。

予備実験では、Cowrieはコマンドの実装数が少なく、Cowrie特有の異常な挙動が多いため、コマンドの追加実装を行い、Cowrie特有の異常な挙動を修正した。実装を施していない純正のCowrieとCowrieにBusyBoxに含まれるコマンドを実装した修正済のCowrieの両方でコマンドログの収集を行い、比較することで、収集ログのパターンの変化を観測できるのではないかと考えた。評価として収集した二つのログをSkip-gramモデルを用いてスコアリングし、どちらがより多くのコマンドログのパターンを収集できているのかを検証した。

その結果、より多くのコマンドパターンを取れたのがCowrieにBusyBoxに含まれるコマンドを実装した修正済のCowrieであるということが明らかとなった。

6.1.1 予備実験の手法

実装を施していない純正のCowrieに対して、これには実装されていないがShellには実装されているコマンドを実装したものを設置し、ログを収集した。

6.1.2 侵入ログの収集環境

6.1.3 実装

純正のCowrieにBusyBoxに含まれるコマンドを実装し、またHoneypot特有の異常な挙動を修正した。ここでの実装を紹介する。

6.1.4 評価

実装を施していない純正の Cowrie と Cowrie に BusyBox に含まれるコマンドを実装した修正済の Cowrie の両方で侵入ログの収集を行い、Word2vec の Skip-Gram Model により次のコマンドの予測、スコアリングを行い比較を行うことで、差異を評価した。スコアリングでは、あるコマンドが実行された時に次のコマンドの出やすさを予測したため、次に実行されるコマンドがスコアとして高い数値を出せばそのコマンドパターンがパターンとして存在しやすいものであることを示す。予備実験の評価に関しては第 7 章の評価で一部説明している。本研究の評価と評価手法の違いは、モデル化を純正の Honeypot に BusyBox に含まれるコマンドを実装したものしか行っていないため、実際の OS に近いログが取れたことが証明できておらず、比較する対象が少なかった。

6.1.5 結果

SSH の低対話型 Honeypot の稼働期間は 12/10 から 2/1(54 日間) で、収集できたものとしてコネクション数、パターン数、コマンド数を以下の表 6.1 に記す。

表 6.1: 予備実験の結果

検知したもの	純正の Honeypot	修正済の Honeypot
コネクション数	19829	27914
パターン数	53	91
コマンド数	470	841

また、モデル化を行い純正の Cowrie と Cowrie に BusyBox に含まれるコマンドを実装した修正済の Cowrie のスコアリングを行なった結果を以下の図 6.1 に記す。横軸はコマンド拡張を行なった Honeypot か素の Honeypot であるかを示している。縦軸は予備実験の評価手法によって算出されたコマンドの表れやすさを数値化したものであり、数値が高くなればのコマンドパターンがパターンとして存在しやすいものであることを示している。予備実験ではコマンドの拡張実装をしたものの方がコマンドパターンとして存在しにくいものを観測できたという結果になった。

本研究の予備実験では、Cowrie に実装されていないコマンドで悪意のある侵入者が使うようなコマンドを実装し、何の追加実装も施していない Cowrie で取れた侵入者の実行コマンドログと、追加実装を施した Cowrie の侵入者の実行コマンドログを比較することで、追加実装を施した SSH の Cowrie の方がコマンドパターンとして多く収集できることを示した。




図 6.1: 純正の Cowrie と修正済の Cowrie のスコアリングによる比較

6.2 評価手法

本研究の仮説の検証手法としての評価として，3.2 節で述べた要件に対して評価を行う．予備実験では，素の低対話型 Honeypot よりも，コマンドを拡張した Honeypot の方がコマンドパターンが多く収集できることを示した．本研究では拡張した Honeypot で収集したコマンドログが，どれほど一般的な UNIX ユーザーの実行するコマンドから離れたのかを評価した．

本研究では，以下の三種類の Honeypot を設置する．

1. 広く利用されている SSH の低対話型 Honeypot
2. 実際の Shell には実装されているが，1. の Honeypot で未実装のコマンドを実装した Honeypot
3. 広く利用されている高対話型 Honeypot

これ以降，1. の広く利用されている SSH の低対話型 Honeypot のことを”純正の低対話型 Honeypot”，2. の実際の Shell には実装されているが，1. の Honeypot で未実装のコマンドを実装した Honeypot のことを”修正済の低対話型 Honeypot”，3. の広く利

用されている高対話型 Honeypot のことを”高対話型 Honeypot”と呼ぶこととする。

また予備実験では，純正の Honeypot に実装されていないコマンドで悪意のある侵入者が使うようなコマンドを実装し，純正の Honeypot で取れた侵入者の実行コマンドログと，修正済の Honeypot の侵入者の実行コマンドログを比較することで，修正済の Honeypot の方がコマンドパターンとして多く収集できることを示した．予備実験における収集ログの比較の概念図を図 6.2 に示す．



図 6.2: 予備実験の評価の概念図

この予備実験では評価として何の追加実装も施していない SSH の低対話型 Honeypot で取れた侵入者の実行コマンドログと追加実装を施した SSH の低対話型 Honeypot の侵入者の実行コマンドログとを比較したのに対して，本件研究の評価手法では，純正の Honeypot で取れた侵入者の実行コマンドログと修正済の Honeypot の侵入者の実行コマンドログと高対話型 Honeypot の侵入者の実行コマンドログを比較することで，修正済の Honeypot の侵入者の実行コマンドログが一般的な UNIX ユーザーの実行するコマンドから離れたのかを評価した．

6.2.1 コマンドログのスコアリング手法の実装の提案

コマンドログの比較を行う手法は多く存在する．例えば評価基準として，あるコマンドが実行された時に，そのコマンドは危険であるとしたブラックリストを作成するパターンマッチングの手法がある．また，攻撃であるとされたコマンドを ?? で説明したマルコフモデルで学習させることで，攻撃性を表現する手法がある．しかしパターンマッチングであれば静的解析であるので未知の攻撃に対応ができず，マルコフモデルであれば現在の状態だけに依存して次の状態への推移確率が決まるので，未知の特徴量を無視してしまうので，いずれも未知の攻撃に対応できない．しかし，2.3 で説明した意味解析をコマンドログに導入することで，コマンド名が別でも同じような内容のコマンドを実行しようとし

た時に、それが同じような内容であることを検知できる自然言語処理における意味解析のニューラルネットワークのモデルを評価基準とすることで未知の攻撃にも対応できる。そのため、本研究では自然言語処理における意味解析のニューラルネットワークのモデルを評価基準とした。

6.2.2 機械学習を用いたコマンドログのスコアリング

本研究では、評価基準となる、自然言語処理における意味解析のニューラルネットワークのモデルとして Word2vec の skip-gram モデルを採用した。純正の低対話型 Honeypot で収集した侵入ログで skip-gram モデルの隠れ層の重みを学習させ (これをモデル 1 とする)、同様にして高対話型 Honeypot で収集した侵入ログも skip-gram モデルの隠れ層の重みを学習させる (これをモデル 2 とする)。次に修正済の Honeypot で収集したログをセッション開始からセッション終了までに打たれたコマンドごとに (以降これを 1 セッションごとと呼ぶ) モデル 1 とモデル 2 のそれぞれに入力していき、出力された数値 a を活性化関数としてソフトマックス関数をかけることで、 $0 \leq a \leq 1$ の範囲を取るようし確率的な数値として出力することでスコアリングを行う。このため入力に対して多数存在する出力を全てを合計すると 1 になる。純正の低対話型 Honeypot や高対話型 Honeypot の収集ログをモデル化する際、入力層として収集ログのコマンドの入力に対してそのコマンドの周辺のコマンドを出力として与えることでこれを学習させる。

例えば 3 つのコマンドが打たれたとしたものを以下のプログラム??に示す。

プログラム 6.1: 3 つの実行コマンドの例

```
1  $  uname
2  $  free
3  $  ps  x
4  $
```

モデルを構築する際には”free”コマンドを入力にした時に、出力として”uname”コマンド”ps”コマンドを用意しておくことで、free が入力として与えられた時に他 2 つの出力される周辺のコマンドが出力する確率が高くなるようにする。また、実装としては周辺語をどこまで広げるのかはパラメータとして window size で与えることができ、上記の例の周辺語は”1”であり、window size を”2”にすればモデル化する際に出力層に与えられる数は 4 つとなる。以下の図 6.3 にモデル化のフローを示す。

また、このようにして Honeypot の収集ログに対して各々のモデルを構築する。モデル



図 6.3: 評価のフロー [1][2]

は *HiddenLayer* に単語ベクトルのインデックスとして構築される．ここで SCDV 2.3.3.4 を使い，word2vec で取得した単語ベクトルを使い，idf 値を計算する．2.3.3.1.1 次に単語ベクトルごとにクラスタリングすることで，ある単語があるクラスタに所属する確率を算出する．クラスタを考慮した新たな単語ベクトルを再構築し，idf 値を考慮した新たな単語ベクトルを再構築する．1 セッションごとに含まれる単語ベクトルを平均化し，文章ベクトルを得る．

6.2.2.1 コマンド群データのベクトル表現の比較

本研究の評価手法によって任意の 2 つのコマンドログを比較した時の，各々のログの違いを文章分類の手法で算出した結果は以下の図 6.2，図 6.3，図 6.4，のようになった．

表 6.2: 修正前と後の honeypot のコマンドログの比較

	正解率	適合率	再現率	F1 値	session 数
素の低対話型 Honeypot	0.807909	0.782520	0.872437	0.825036	3951
修正済の低対話型 Honeypot	0.807909	0.842795	0.738251	0.787067	3660

表 6.3: 修正前の honeypot と一般 UNIX ユーザーのコマンドログの比較


	正解率	適合率	再現率	F1 値	session 数
素の低対話型 Honeypot	0.778404	0.788169	0.765108	0.776467	3657
一般の UNIX ユーザー	0.778404	0.769086	0.791863	0.780308	3613

表 6.4: 修正後の honeypot と一般 UNIX ユーザーのコマンドログの比較

	正解率	適合率	再現率	F1 値	session 数
素の低対話型 Honeypot	0.822134	0.793420	0.892497	0.840047	3972
修正済の低対話型 Honeypot	0.822134	0.863229	0.744887	0.799703	3618

上記の表から，素の Honeypot と一般ユーザーのコマンドログが一番近く，修正済の Honeypot と一般ユーザーのコマンドログが一番遠いことが分かった．すなわち，ベクトル空間上において一般ユーザーのコマンドログの文章ベクトルを原点 O とし，素の Honeypot コマンドログの文章ベクトルと A ，修正済の Honeypot コマンドログの文章ベクトルと B とした時に， $|\vec{OA}| < |\vec{AB}| < |\vec{OB}|$ であり，なす角 $\angle AOB$ は鋭角である．以下略図を示す．

したがって， $0 < n$ を満たす n と任意のベクトル $\vec{\alpha}$ を使うと， \vec{OB} は $\vec{OB} = (1+n)\vec{OA} + \vec{\alpha}$ と表すことができる．したがって，修正済の Honeypot のコマンドログは一般ユーザーのコマンドログを始点とすると，素の Honeypot のコマンドログのベクトル方向よりも正の



向きに遠くに位置することが分かった.

また, SCDV によって獲得した各々の Honeypot の攻撃ログにおける文章ベクトルを, t-SNE で次元削減することで可視化を行なった結果を図 6.4, 図 6.5, 図 6.6 に示す.




図 6.4: 修正前と後の honeypot のコマンドログの文章ベクトルの可視化




図 6.5: 修正前の honeypot と一般 UNIX ユーザーのコマンドログの文章ベクトルの可視化




図 6.6: 修正後の honeypot と一般 UNIX ユーザーのコマンドログの文章ベクトルの可視化

上記の図において，Fixed-Low-Interaction-Honeypot（修正済の Honeypot）は Pure-Low-Interaction-Honeypot よりも広く分布していることが分かり，他のログでは取れていないログを取得できたことが分かる．

6.3 考察

文章ベクトルの意味解析において高い精度を持つ [17]SCDV を用いた素の低対話型 Honeypot と修正済の Honeypot，高対話型 Honeypot の攻撃ログを文章ベクトル空間上で比較した結果，修正済の Honeypot のコマンドログは一般ユーザーのコマンドログを始点とすると，素の Honeypot のコマンドログのベクトル方向よりも正の向きに遠くに位置することが分かり，素の Honeypot のコマンドログと比較して，修正済の Honeypot は一般の Unix ユーザーのコマンドログにとっての異常なコマンドログを収集できることを示した．また，高対話型 Honeypot の攻撃ログの取得数が極端に少なく，その原因は，その Honeypot のサポートが最新版が 2009 年であり，対策を施されてしまった結果ではないかと考えられる．

第7章 関連研究

7.1 関連研究

本章では、SSH の Honeypot と時系列データの処理に関連する先行研究について紹介する。

7.1.1 AccessTracer

日本電気株式会社中央研究所の開発した異常行動検出エンジン AccessTracer[20] において、ユーザーの UNIX コマンドの履歴をオンライン忘却型学習アルゴリズムによる行動モデルの学習によってユーザーの普段と違うコマンド履歴を検知することができる。本研究のモデル構築におけるモデルの作成方法が異なる。

7.1.2 自然言語処理における意味解析

2.3 で述べたように、自然言語処理とは人間が日常的に使っている自然言語をコンピュータに処理させる一連の技術である。現在、意味解析において大きくシソーラス解析とベクトル空間分析の2つが手法として多く、本研究ではこのうちベクトル空間分析を使用した。そのため関連研究ではベクトル空間解析について述べる。

7.1.2.1 ベクトル空間解析

2.3.3 で述べたように、自然言語処理の意味解析の手法の一つにベクトル空間解析というものがある。本研究で取得した Honeypot のデータを用いて、ベクトル空間解析の方法でも評価を試みた。word2vec だけによる比較は以下の表 7.1 の通り。

表 7.1: word2vec による各々の honeypot のコマンドログの比較

	正解率	適合率	再現率	F1 値	セッション数
素の低対話型 Honeypot	0.648172	0.638172	0.697262	0.719872	3629
修正済みの低対話型 Honeypot	0.793772	0.828741	0.768549	0.847428	3939
高対話型 Honeypot	0.619941	0.628721	0.559174	0.608271	44
攻撃者ではない UNIX の User	0.691876	0.753382	0.691302	0.700291	3671

word2vec は、単語ベクトルのクラスタリングを行なった SCDV による評価と比較して、全ての評価基準においてやや精度の低い結果となった。

7.1.2.1.1 ベクトル空間モデル

2.3.3.1 で述べたように、ベクトル空間解析にはベクトル空間モデルというものが存在する。2.3.3.1.1 で述べた TF-IDF を用いて、同一文章内での単語の出現頻度と、様々な文章におけるある単語の逆文書頻度の 2 つを重みとし、文章を多次元マトリクスで表現する。文章同士の距離をなす角 θ の、 $0^\circ \leq \theta \leq 90^\circ$ における $\cos \theta$ の値の大きさによって文章の類似度を算出する。多次元マトリクスにおける 2 つの文章のベクトルの方向は文章の特徴であるので、 $0^\circ \leq \theta \leq 90^\circ$ において θ の値が小さくなればなるほど、つまり $\cos \theta$ の値が大きくなればなるほど文章同士の類似度が高いということになる。ref で示したように、TF-IDF で重み付けされたベクトル空間モデルの $\cos \theta$ の値は、 m 個の単語が使用されている文章 d における各単語の重要度を $w_{d1}, w_{d2}, w_{d3}, \dots, w_{dm}$ とし、同様に n 個の単語が使用されている文章 e における各単語の重要度を $w_{e1}, w_{e2}, w_{e3}, \dots, w_{en}$ とすると、

$$\cos \theta = \frac{\sum_{i=1}^m ((tf(t_i, d) \cdot idf(t_i))(tf(t_i, e) \cdot idf(t_i))}{\sum_{i=1}^m \sqrt{(tf(t_i, d) \cdot idf(t_i))^2} \sum_{i=1}^n \sqrt{(tf(t_i, e) \cdot idf(t_i))^2}}$$

である。

第8章 結論

本章では，本研究のまとめと今後の課題を示す．

8.1 本研究のまとめ

本研究では，侵入者から Honeypot であることの検知を回避するために，低対話型 Honeypot の実行コマンドの挙動を本物の Shell の実行コマンドの挙動に近づけることを提案した．侵入者から Honeypot であることの検知を回避するためには，本物の Shell に実装されているコマンドの実装と，低対話型 Honeypot 特有の異常な挙動をするコマンドの修正を行う必要がある．そこで，本物の Shell に実装されているコマンドを低対話型 Honeypot に全て実装し，低対話型 Honeypot 特有の異常な挙動をするコマンドの修正を行った．低対話型 Honeypot の実行コマンドの挙動を本物の Shell の実行コマンドも挙動に近づけたかを検証するために，追加実装を施していない低対話型 Honeypot とコマンド拡張を行なった低対話型 Honeypot，高対話型 Honeypot を設置してコマンドログを収集し，一般の UNIX ユーザーの実行コマンドログと比較した．コマンドログの自然言語処理による意味解析を行ない，個々のコマンドの意味を多次元のベクトル空間上で表現することで，コマンド拡張を行なった低対話型 Honeypot のコマンドログが素の低対話型 Honeypot と比較して，一般的な UNIX ユーザーの実行するコマンドログから離れたことを明らかにした．このことから，素の Honeypot にコマンド拡張を行い，低対話型 Honeypot の実行コマンドの挙動を本物の Shell の実行コマンドの挙動に近づけることで，拡張した低対話型 Honeypot で取れたコマンドログが様々な攻撃パターンと異常な挙動を収集できることを確認した．

8.2 本研究の課題と展望

本節では，提案手法の課題とその展望を述べる．SSH の低対話型 Honeypot に実装するコマンドについて，ディストリビューションごとに実装コマンドが異なるが，今回は BusyBox をそのまま Python で実装した．したがって，低対話型 Honeypot がエミュレーションしているディストリビューションで実装されているコマンドは必要条件しか満たしていない．また，3.1.1.1 で述べた通り，低対話型 Honeypot には本研究と着目した問題以外にも，SSH でのセッション確立におけるレイテンシの問題や，Honeypot の Username の問題も存在する．しかし本研究ではこれらを扱わず，本物の Shell の挙動を完全にエミュ

レートできていないため，侵入者から Honeypot であることを検知されてしまう可能性はまだ残されている．

8.2.1 文章ベクトルの評価指標

SCDV における評価指標，Accuracy, precision, recall, f1-score, による評価指標の良し悪し．

8.2.2 高対話型 Honeypot のログ収集の不足

高対話型 Honeypot では全然収集できなかった～～～

8.2.3 ネットワークセグメントによるログ収集環境の違い

ORF では～～～さくらでは～～～

8.2.4 ディストリビューションごとの実装コマンド

ディストリビューションごとの実装コマンドについてはバージョンの問題にも依存する．しかし，OS のリリースには LTS(Long Term Support) があり，広く使われている OS の実装コマンドの検証は十分に可能である．

8.2.5 様々な Honeypot のコマンドログの精度評価への応用

現在様々な種類の SSH の低対話型 Honeypot が普及しているおり，それらの Honeypot ごとに実装コマンドが異なる．そのため，Honeypot の種類ごとに攻撃ログを収集し，本研究の評価手法を用いることで，自然言語処理による意味解析において使用した Honeypot で取れたコマンドログが，高対話型 Honeypot のコマンドログにどれほど空間的距離が近いのかを検証することができる．

8.2.6 コマンド系ごとの評価への応用

SSH の低対話型 Honeypot を設置し，自然言語処理による意味解析を行なったコマンドログにおいて，個々のコマンドごとに持つ意味が異なる，あるコマンドが使用できないような実装を施すと高対話型 Honeypot のコマンドログにどれほど空間的距離が遠くなるかを検証できる．

付 録 A 付録

A.1 実装コマンド

A.1.1 純正の Honeypot で未実装のコマンド種類

実装コマンド一覧

BusyBox に含まれるコマンドと Cowrie の実装コマンドの一覧

表 A.1: 実装コマンド一覧

Cowrie の実装コマンド	Busybox に含まれるコマンド	Cowrie に未実装のコマンド
adduser	acpid	acpid
alias	adjtimex	adjtimex
apt-get	ar	ar
base64	arp	arp
bash	arping	arping
busybox	ash	ash
cat	awk	awk
cd	basename	basename
chattr	blockdev	blockdev
chgrp	brctl	brctl
chmod	bunzip2	bunzip2
chown	bzcat	bzcat
clear	bzip2	bzip2
cp	cal	cal
curl	cat	chpasswd
date	chgrp	chroot
dd	chmod	chvt
dget	chown	cmp
dir	chpasswd	cpio
du	chroot	crond
echo	chvt	crontab

次ページに続く

前ページからの続き

Cowrie の実装コマンド	Busybox に含まれるコマンド	Cowrie に未実装のコマンド
egrep	clear	cttyhack
env	cmp	cut
ethtool	cp	dc
exit	cpio	deallocvt
export	crond	depmod
fgrep	crontab	devmem
free	cttyhack	df
ftpget	cut	diff
gcc	date	dirname
grep	dc	dmesg
halt	dd	dnsdomainname
head	deallocvt	dos2unix
help	depmod	dpkg
history	devmem	dpkg-deb
hostname	df	dumpkmap
id	diff	dumpleases
ifconfig	dirname	ed
iptables	dmesg	expand
jobs	dnsdomainname	expr
kill	dos2unix	FALSE
killall	dpkg	fdisk
killall5	dpkg-deb	find
last	du	fold
logout	dumpkmap	freeramdisk
ls	dumpleases	fstrim
mkdir	echo	ftpput
mv	ed	getopt
nc	egrep	getty
netstat	env	groups
nohup	expand	gunzip
passwd	expr	gzip
perl	FALSE	hexdump
php	fdisk	hostid
ping	fgrep	httpd
pkill	find	hwclock
poweroff	fold	ifdown

次ページに続く

前ページからの続き

Cowrie の実装コマンド	Busybox に含まれるコマンド	Cowrie に未実装のコマンド
printf	free	ifup
ps	freeramdisk	init
pwd	fstrim	insmod
python	ftpget	ionice
reboot	ftpput	ip
reset	getopt	ipcalc
rm	getty	klogd
rmdir	grep	less
scp	groups	ln
service	gunzip	loadfont
set	gzip	loadkmap
sh	halt	logger
shutdown	head	login
sleep	hexdump	logname
ssh	hostid	logread
su	hostname	losetup
sudo	httpd	lsmod
tail	hwclock	lzcat
tar	id	lzma
tftp	ifconfig	lzop
touch	ifdown	lzopcat
ulimit	ifup	md5sum
umask	init	mdev
uname	insmod	microcom
unset	ionice	mkfifo
uptime	ip	mknod
useradd	ipcalc	mkswap
users	kill	mktemp
w	killall	modinfo
wget	klogd	modprobe
which	last	more
who	less	mount
whoami	ln	mt
yes	loadfont	nameif
yum	loadkmap	nslookup
	logger	od

次ページに続く

前ページからの続き

Cowrie の実装コマンド	Busybox に含まれるコマンド	Cowrie に未実装のコマンド
	login	openvt
	logname	patch
	logread	pidof
	losetup	ping6
	ls	pivot_root
	lsmod	rdate
	lzcat	readlink
	lzma	realpath
	lzop	renice
	lzopcat	rev
	md5sum	rmmod
	mdev	route
	microcom	rpm
	mkdir	rpm2cpio
	mkfifo	run-parts
	mknod	sed
	mkswap	seq
	mktemp	setkeycodes
	modinfo	setsid
	modprobe	sha1sum
	more	sha256sum
	mount	sha512sum
	mt	sort
	mv	start-stop-daemon
	nameif	stat
	nc	static-sh
	netstat	strings
	nslookup	stty
	od	sulogin
	openvt	swapoff
	passwd	swapon
	patch	switch_root
	pidof	sync
	ping	sysctl
	ping6	syslogd
	pivot_root	tac

次ページに続く

前ページからの続き

Cowrie の実装コマンド	Busybox に含まれるコマンド	Cowrie に未実装のコマンド
	poweroff	taskset
	printf	tee
	ps	telnet
	pwd	telnetd
	rdate	test
	readlink	time
	realpath	timeout
	reboot	top
	renice	tr
	reset	traceroute
	rev	traceroute6
	rm	TRUE
	rmdir	tty
	rmmod	tunctl
	route	udhcpc
	rpm	udhcpd
	rpm2cpio	umount
	run-parts	uncompress
	sed	unexpand
	seq	uniq
	setkeycodes	unix2dos
	setsid	unlzma
	sh	unlzop
	sha1sum	unxz
	sha256sum	unzip
	sha512sum	usleep
	sleep	uudecode
	sort	uuencode
	start-stop-daemon	vconfig
	stat	vi
	static-sh	watch
	strings	watchdog
	stty	wc
	su	xargs
	sulogin	xz
	swapoff	xzcat

次ページに続く

前ページからの続き

Cowrie の実装コマンド	Busybox に含まれるコマンド	Cowrie に未実装のコマンド
	swapon	zcat
	switch_root	
	sync	
	sysctl	
	syslogd	
	tac	
	tail	
	tar	
	taskset	
	tee	
	telnet	
	telnetd	
	test	
	tftp	
	time	
	timeout	
	top	
	touch	
	tr	
	traceroute	
	traceroute6	
	TRUE	
	tty	
	tunctl	
	udhcp	
	udhcpd	
	umount	
	uname	
	uncompress	
	unexpand	
	uniq	
	unix2dos	
	unlzma	
	unlzop	
	unxz	
	unzip	

次ページに続く

前ページからの続き

Cowrie の実装コマンド	Busybox に含まれるコマンド	Cowrie に未実装のコマンド
	uptime	
	usleep	
	uudecode	
	uuencode	
	vconfig	
	vi	
	watch	
	watchdog	
	wc	
	wget	
	which	
	who	
	whoami	
	xargs	
	xz	
	xzcat	
	yes	
	zcat	

以上

A.1.2 純正の Honeypot で未実装のコマンドの実装

プログラム A.1: acpid

```
1 # coding: utf-8
2
3 import subprocess
4
5 cmd = "acpid"
6 subprocess.call(cmd.split())
```

プログラム A.2: adjtimex

```
1 # coding: utf-8
2
3 import subprocess
4
5 cmd = "adjtimex"
6 subprocess.call(cmd.split())
```

プログラム A.3: adjtimex -p

```
1 # coding: utf-8
2
3 import subprocess
4
5 cmd = "adjtimex -p"
6 subprocess.call(cmd.split())
```

プログラム A.4: ar

```
1 # coding: utf-8
2
3 import subprocess
4 import sys
5
6 cmd = "ar -t"
7 opt = sys.argv[1]
8 cmdall = cmd + " " + opt
9 subprocess.call(cmdall.split())
```

プログラム A.5: arp


```
1 # coding: utf-8
2
3 import subprocess
4
5 cmd = "arp"
6 subprocess.call(cmd.split())
```

プログラム A.6: arping

```
1 # coding: utf-8
2
3 import subprocess
4
5 cmd = "arping"
6 subprocess.call(cmd.split())
```

プログラム A.7: ash

```
1 # coding: utf-8
2
3 string = '''-bash: ash: command not found'''
4
5 print(string)
```

謝辞

俺と俺に関わった全てに感謝

参考文献

- [1] Greg Corrado Jeffrey Dean Tomas Mikolov, Kai Chen. Efficient estimation of word representations in vector space. *ACM Transactions on Graphics (TOG)*, 32(4):138, 2013.
- [2] Xin Rong. Word2vec parameter learning explained. *ACM Transactions on Graphics (TOG)*, 32(4):138, 2013.
- [3] honeynet. High-interaction-honeypot. <https://projects.honeynet.org/honeywall/>, 2014.
- [4] Ken Fujiyoshi, Chihiro Fukai, Hiroya Tanaka, Jin Mitsugi, and Jun Murai. Honeypot. *NIP & Digital Fabrication Conference 2014 1*, pages 316–319, 2014.
- [5] Kippo. <https://github.com/desaster/kippo/>.
- [6] Single board computer. <http://fablabjapan.org/>.
- [7] Kippo のプロジェクトの現在. <http://www.thingiverse.com/>.
- [8] Number of kippo'commands. <https://github.com/desaster/kippo/tree/master/txtcmds>.
- [9] Number of cowrie'commands. <https://github.com/cowrie/cowrie/tree/master/src/cowrie/commands>.
- [10] 消費者庁. Kippo と cowrie の実装コマンドの違い. <https://etherscan.io/stat/miner>, 1992.
- [11] honeynet. honeywall. <https://projects.honeynet.org/honeywall/>, 2014.
- [12] Karl DD Willis and Andrew D Wilson. Secure shell. *ACM Transactions on Graphics (TOG)*, 32(4):138, 2013.
- [13] Busybox. <https://proofofexistence.com/>.
- [14] Wordnet. <https://wordnet.princeton.edu/>.
- [15] Wordnet wikipedia. <https://ja.wikipedia.org/wiki/WordNet/>.

- [16] 出口 利憲. ベクトル空間法による文書の類似度の算出. <http://www.gifu-nct.ac.jp/elec/deguchi/sotsuron/hayashi/node20.html/>, 2010.
- [17] Bhargavi Paranjape Harish Karnick Dheeraj Mekala, Vivek Gupta. Scdv : Sparse composite document vectors using soft clustering over distributional representations. <https://arxiv.org/pdf/1612.06778.pdf>, 2017.
- [18] Cowrie. <https://github.com/cowrie/cowrie/>.
- [19] soji256. dmidecodecommand. <https://soji256.hatenablog.jp/entry/2018/09/06/075700/>, 2018.
- [20] 山西健司・竹内純一・丸山祐子. データマイニングに基づくセキュリティ・インテリジェンス技術の研究開発. 先端技術大賞応募論文, 19:14, 2004.